DEEP LEARNING FOR EEG DECODING: A COMPRHENSIVE SURVEY

基于深度学习的脑电译码工程实现

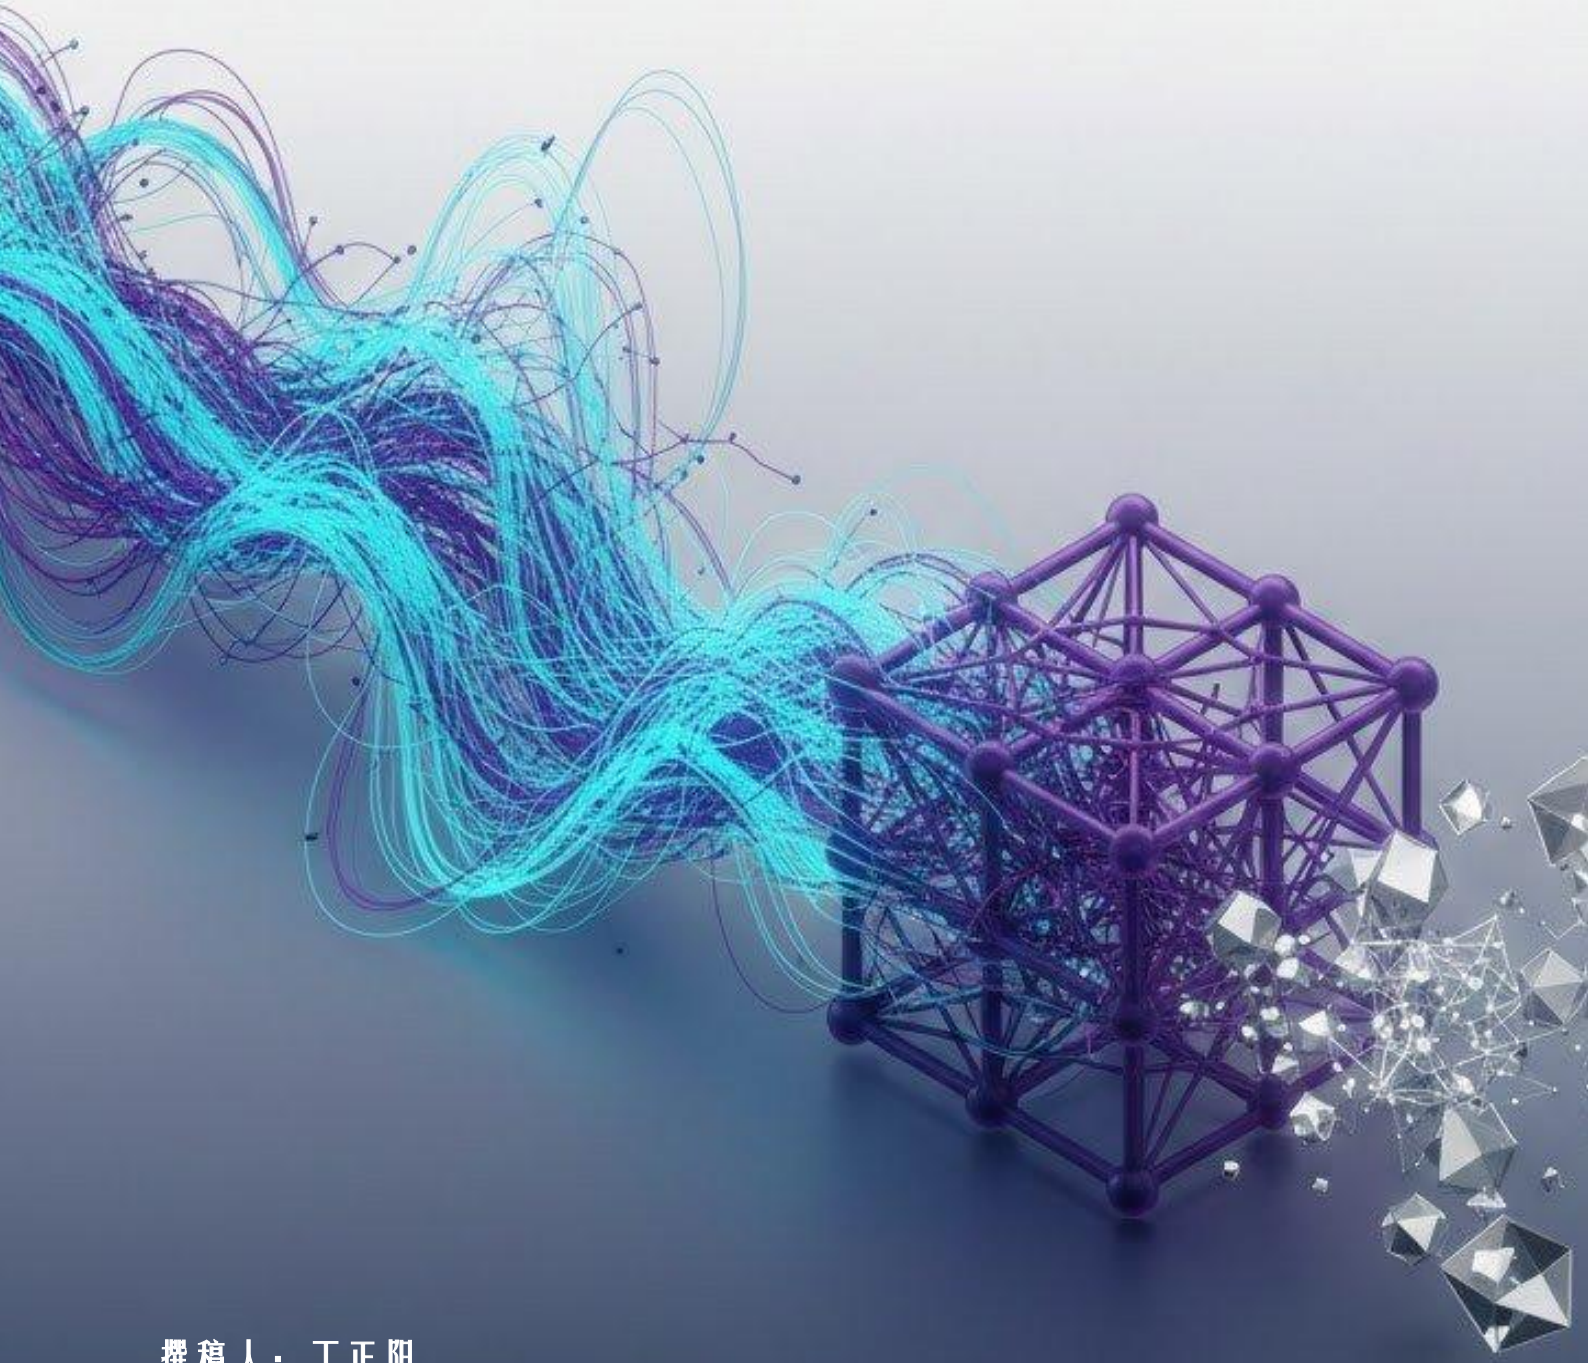

撰稿人：丁正阳

摘要

脑机接口技术的发展高度依赖于从头皮脑电图中准确解码用户意图。然而，EEG 信号固有的特性，使得传统解码方法面临泛化瓶颈。尽管深度学习引入了端到端的学习范式，但现有文献缺乏对新兴架构及标准化实验流程的系统性梳理。本文对基于深度学习的 EEG 解码技术进行了全面综述。首先，我们提出了多架构分类体系。其次，我们提炼了一套标准化工作流。结果分析表明，端到端模型在复杂认知任务中显著优于传统方法，且混合架构展现出了更优的鲁棒性。最后，本文探讨了跨受试者泛化的局限性，并指出了未来的核心突破方向。

关键词： 脑机接口；脑电图；深度学习；图神经网络；Transformer；泛化能力

Abstract

The advancement of Brain-Computer Interface (BCI) technology relies heavily on the accurate decoding of user intentions from scalp electroencephalography (EEG). However, the inherent characteristics of EEG signals cause traditional decoding methods to face generalization bottlenecks.

Although deep learning has introduced end-to-end learning paradigms, existing literature lacks a systematic review of emerging architectures and standardized experimental pipelines. This paper presents a comprehensive review of deep learning-based EEG decoding techniques. First, we propose a multi-architecture taxonomy. Second, we distill a standardized workflow.

The analysis of results indicates that end-to-end models significantly outperform traditional methods in complex cognitive tasks, and that hybrid architectures exhibit superior robustness. Finally, this paper discusses the limitations of cross-subject generalization and identifies key directions for future breakthroughs.

Keywords: Brain-Computer Interface (BCI); Electroencephalography (EEG); Deep Learning; Graph Neural Networks (GNN); Transformer; Generalization Ability

目录

1 引言 3
1.1 问题综述 3
1.2 研究的必要性 4
1.3 明确目的与提出假设 5
2 材料与方法 8
2.1 数据集 8
2.2 数据预处理与变换 9
2.3 定义与标准 11
2.4 数据收集与验证策略 12
2.5 统计检验/评估指标与优化目标 14
3 研究结果描述 16
3.1 描述性统计与基线群体比较 16
3.2 程序性结果与分类结果 17
3.3 数据有效性的度量与鲁棒性分析 19
3.4 统计分析结果 20
4 假设验证与讨论 22
4.1 主要假设讨论 22
4.2 假设的深入解读 23
4.3 研究的局限性 24
5 总结与未来展望 27
5.1 总结 27
5.2 未来展望 28
参考文献 30

基于深度学习的脑电译码工程实现研究

1 引言

1.1 问题综述

脑机接口（Brain-Computer Interface, BCI）作为连接人脑与外部设备的直接通信通路，近年来在神经康复、增强控制及情感计算等领域展现出巨大的应用潜力。然而，作为 BCI 系统的核心，从头皮脑电图（Electroencephalogram, EEG）中准确、鲁棒地解码用户意图或心理状态，始终是一个极具挑战性的科学难题。这一问题的根源在于 EEG 信号本身极其复杂的生物物理特性及其采集过程中不可避免的噪声干扰[1]。

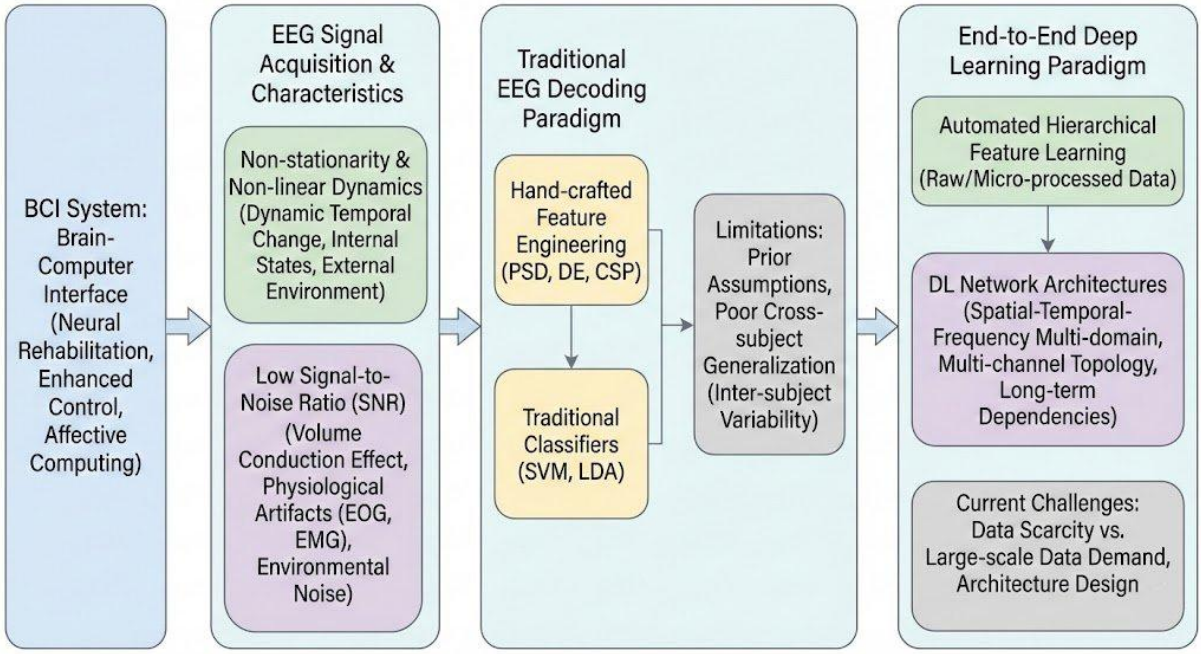

Figure 1 脑电信号解码方法演变与范式转变

首先，EEG 信号具有显著的非平稳性（Non-stationarity）和非线性动力学特征[1]。脑电活动随时间动态变化，受大脑内部状态（如疲劳、注意力波动）及外部环境的共同影响，导致同一受试者在不同时间段（Cross-session）甚至同一任务内的信号分布发生漂移。其次，EEG 信号具有极低的信噪比（SNR）。由于电极贴附于头皮，记录到的微伏级电位变化不仅经过了颅骨和头皮的容积导体效应（Volume Conduction Effect）的模糊化处理，还混杂了大量的生理伪迹（如眼电 EOG、肌电 EMG）和环境工频干扰。这使得从原始信号中提取与特定认知任务相关的有效特征变得异常困难。

传统的 EEG 解码流程高度依赖于手工特征工程（Hand-crafted Feature Engineering）。研究者通常利用信号处理技术提取功率谱密度（PSD）、微分熵

（DE）、共同空间模式（CSP）等特征，再输入到支持向量机（SVM）或线性判别分析（LDA）等传统分类器中。然而，这种“特征提取+分类”的分离式范式存在明显的局限性：手工特征往往依赖于先验假设（如假设特定频段包含关键信息），难以捕捉信号中潜在的高维、非线性时空依赖关系；此外，传统方法在面对跨被试（Cross-subject）场景时，由于无法有效处理个体差异（Inter-subject variability），其泛化能力往往大幅下降[2]。

随着深度学习（Deep Learning, DL）在计算机视觉和自然语言处理领域的爆发，端到端（End-to-End）的学习范式逐渐被引入 EEG 解码中[3]。深度神经网络理论上能够自动从原始或微处理的数据中学习分层特征表示，从而规避手工特征提取的繁琐与局限。然而，如何设计适配 EEG 独特的时-空-频多域特性的网络架构（如处理多通道的空间拓扑关系、时间序列的长期依赖性），以及如何解决深度模型对大规模标注数据的渴求与 EEG 数据稀缺之间的矛盾，成为了当前该领域亟待解决的核心问题[4]。

1.2 研究的必要性

尽管基于深度学习的 EEG 分析已成为当前的研究热点，但在现有的文献体系中，仍然缺乏一个系统性、标准化且紧跟前沿技术架构的综述框架，这在很大程度上阻碍了该领域的进一步发展与技术落地。现有的综述文章往往存在以下几个方面的不足，使得本研究的开展显得尤为必要。

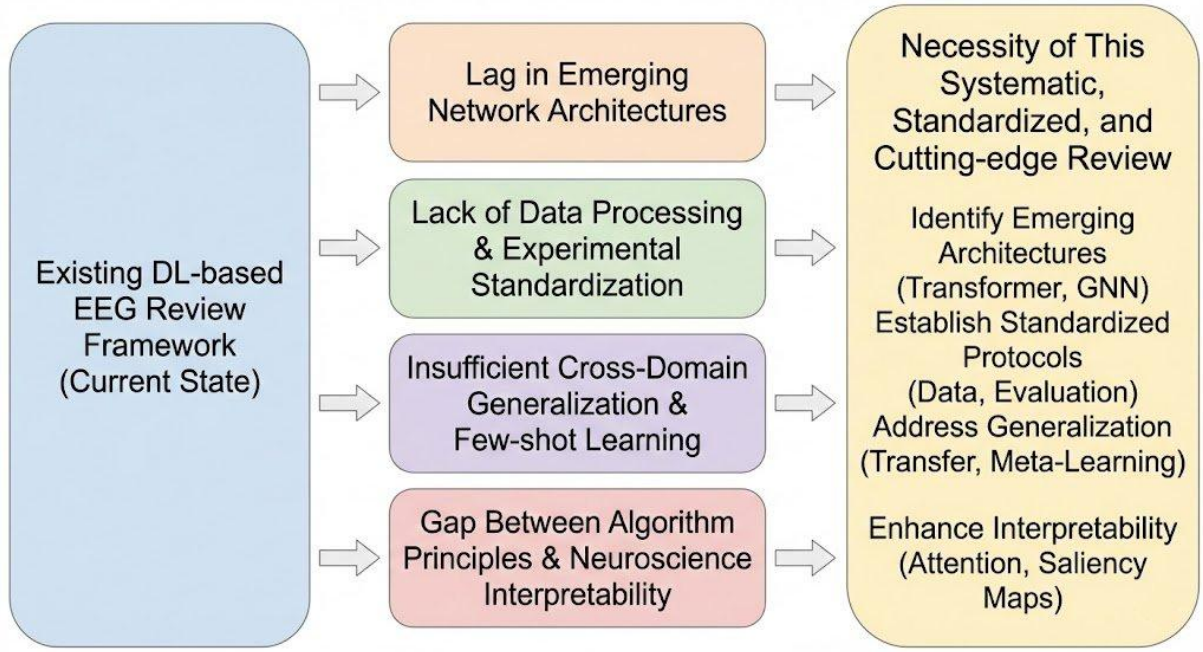

Figure 2 基于深度学习的脑电综述框架：现状、挑战与前沿方向

首先，现有文献对新兴网络架构的梳理存在滞后性。早期的综述主要集中在卷积神

经网络（CNN）和循环神经网络（RNN）的基本应用上，而对于近年来在通用人工智能领域大放异彩的 Transformer 架构、自注意力机制（Self-Attention Mechanism）以及图神经网络（GNN）在 EEG 领域的适配性研究缺乏深入的探讨[5]。EEG 信号不仅是时间序列，更具有基于电极位置的图拓扑结构，如何利用 GNN 捕捉脑区间的动态功能连接，或利用 Transformer 捕捉长距离的时间依赖，是当前最前沿的研究方向，急需系统的归纳与总结。

其次，数据处理与实验协议的标准化严重缺失。在深度学习模型的训练中，数据预处理（如滤波频段选择、数据切分策略）、数据增强（Data Augmentation）以及训练集/测试集的划分方式（如留一受试者交叉验证）对最终结果有着决定性影响。然而，不同研究往往采用各异的预处理流程和评估标准，导致不同模型之间的性能对比缺乏公平性。本综述旨在通过总结当前主流的开源工具库和基准数据集的处理规范，提炼出一套通用的实验方法论，以解决目前领域内存在的“复现难”和“对比难”的问题。

再者，跨域泛化与小样本学习（Few-shot Learning）的讨论不足[6]。实际应用中的 BCI 系统面临着严重的“冷启动”问题，即新用户往往无法提供大量的校准数据。因此，如何利用迁移学习（Transfer Learning）、域适应（Domain Adaptation）以及元学习（Meta-Learning）技术，挖掘受试者无关（Subject-independent）的通用脑电特征，是实现 BCI“即插即用”的关键[7]。目前的综述多关注单一受试者内的分类精度，而对跨被试、跨数据集的泛化性能及其背后的理论支撑探讨不足。

最后，本研究不仅是对现有算法的罗列，更是为了填补算法原理与神经科学解释性之间的鸿沟。深度学习常被视为“黑盒”，而在临床和脑科学研究中，模型的可解释性（Interpretability）至关重要。本综述将特别关注那些能够通过注意力权重图、显著性图等方式反向解析大脑活动模式的研究，从而论证深度学习不仅是分类工具，更是探索大脑认知机制的有力手段。

1.3 明确目的与提出假设

本文旨在对基于深度学习的 EEG 解码技术进行全面、深入且结构化的综述，重点聚焦于近年来涌现的先进模型架构、数据处理流水线以及复杂场景下的泛化策略。我们的核心目的是构建一个连接底层信号处理与高层语义理解的知识框架，为 BCI 研究者提供从数据准备、模型选择到性能评估的全链路指导。

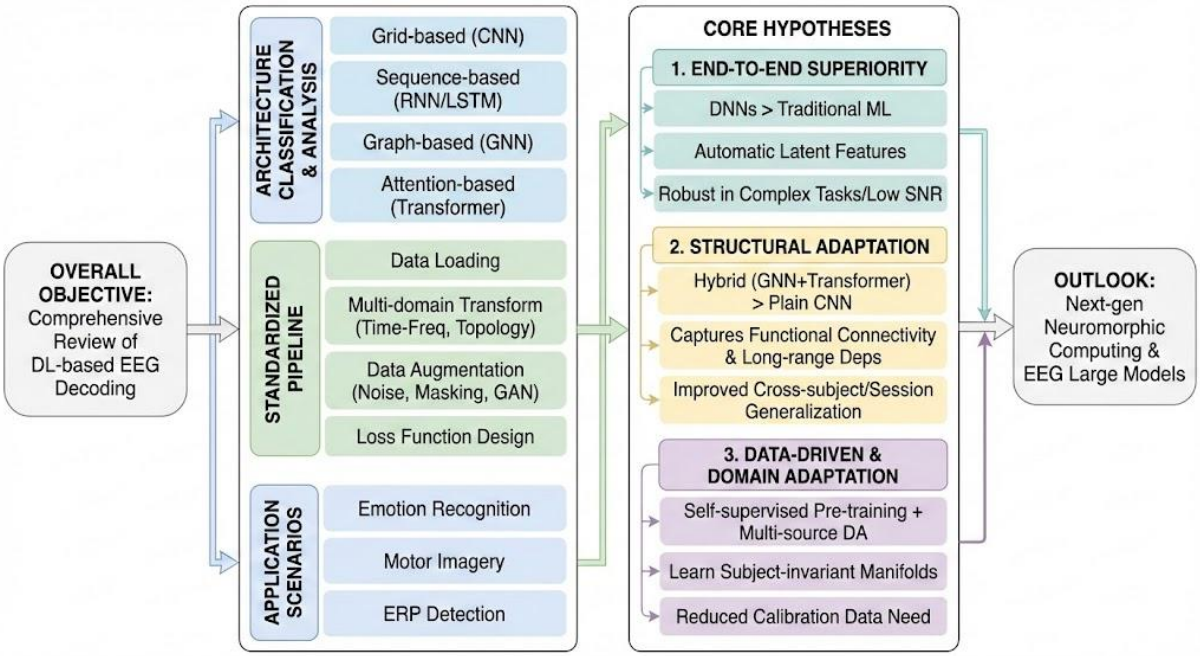

Figure 3 深度学习脑电解码综述：总体框架、核心假设与路线图

具体而言，本文设定了以下几个明确的研究目的：

1.3.1 架构分类与解析

我们将系统地将现有的深度学习模型划分为基于网格（Grid-based，如 CNN）、基于序列（Sequence-based，如 RNN/LSTM）、基于图（Graph-based，如 GNN）以及基于注意力（Attention-based，如 Transformer）四大类。对于每一类架构，我们将深入剖析其如何针对 EEG 的时空特性进行改进。例如，分析 CNN 如何通过不同尺寸的卷积核提取频域特征，或 GNN 如何利用邻接矩阵模拟脑电极间的空间关系。

1.3.2 标准化流程的提炼

参考当前主流开源框架的设计逻辑，我们将总结一套标准化的 EEG 深度学习工作流（Pipeline）。这包括从原始数据的加载、多域变换（时频图、拓扑图生成）、数据增强策略（如加噪、掩码、生成对抗网络 GAN 合成）到模型训练的损失函数设计。我们将特别探讨如何通过标准化流程来提升实验结果的可复现性。

1.3.3 应用场景的深度覆盖

本文将涵盖情感识别、运动想象（Motor Imagery）、事件相关电位（ERP）检测等多个核心任务，分析不同任务对模型架构的差异化需求。

基于上述目的，本文提出以下核心假设（Hypothesis）：

1.3.4 端到端优越性假设

相比于依赖人工特征的传统机器学习方法，设计良好的深度神经网络能够自动提取出更具鲁棒性和判别力的潜在特征表示（Latent Representations），从而在复杂认知任务（如情感识别）和低信噪比环境下取得更优的解码性能[8]。

1.3.5 结构适配性假设

考虑到 EEG 信号非欧几里得的空间分布和长时序特性，结合了图拓扑建模（GNN）和全局注意力机制（Transformer）的混合架构，在捕捉脑区间的功能连接和长时依赖方面，将优于单纯的局部卷积网络（CNN），从而在跨被试和跨会话的泛化任务中表现出更高的稳定性[9]。

1.3.6 数据驱动与域适应假设

通过引入无监督预训练（Self-supervised Pre-training）和多源域适应（Multi-source Domain Adaptation）技术，模型可以从大规模未标注或异构数据中学习到受试者不变（Subject-invariant）的流形结构，从而显著降低新用户校准所需的数据量，验证深度学习在解决 BCI 个体差异问题上的有效性。

通过对文献的详尽梳理和对比分析，本文将验证上述假设，并最终展望下一代神经形态计算与脑电大模型的发展方向。

2 材料与方法

2.1 数据集

在基于深度学习的脑电译码研究中，“研究对象”的概念通常通过标准化的基准数据集（Benchmark Datasets）来体现。与传统小规模临床实验不同，深度学习模型对数据规模有着极高的渴求，因此，本综述所涵盖的研究主要基于一系列公认的开源数据集，这些数据集涵盖了不同的 BCI 范式，确保了算法性能的可比性与复现性。

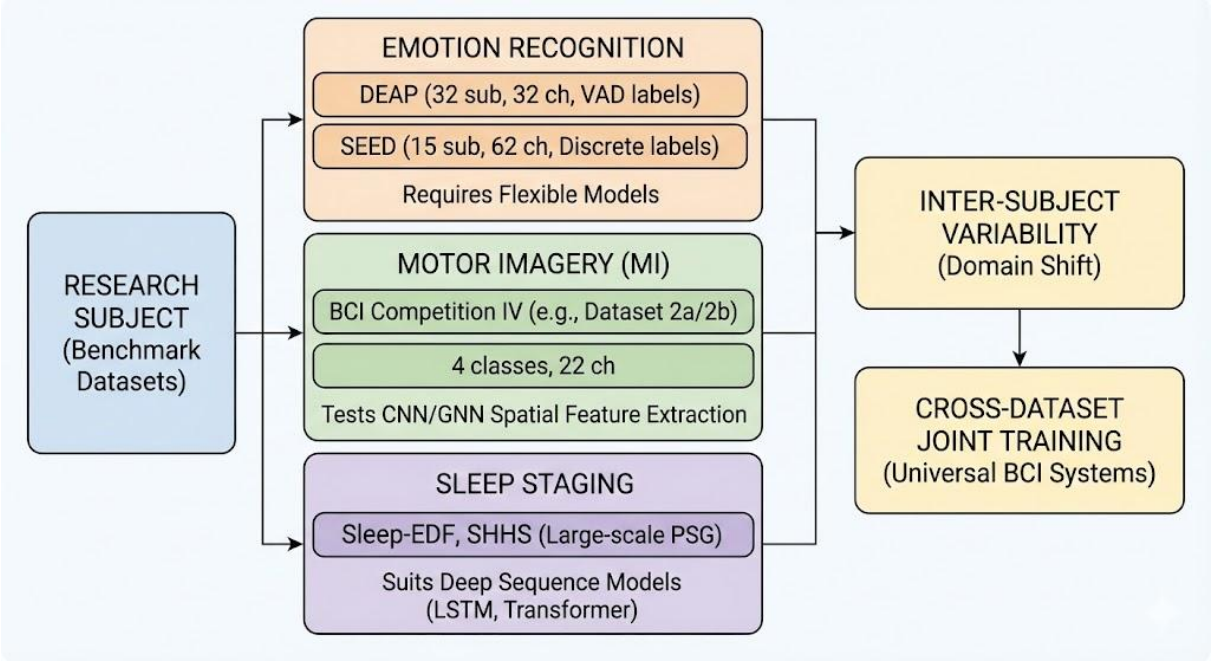

Figure 4 脑电解码三大应用场景及其数据集

2.1.1 情绪识别数据集

在情绪识别（Emotion Recognition）领域，最具代表性的数据集包括 DEAP（Database for Emotion Analysis using Physiological Signals）和 SEED（SJTU Emotion EEG Dataset）。DEAP 包含 32 名受试者在观看 40 段音乐视频时的多模态生理信号[10]，记录了 32 通道的 EEG 数据，并提供了基于效价（Valence）、唤醒度（Arousal）和支配度（Dominance）的连续维度标注。SEED 数据集则侧重于跨时间段的稳定性研究[11]，记录了 15 名受试者在不同时间段观看电影片段时的 62 通道 EEG 数据，提供了离散的情绪标签（积极、中性、消极）。这些数据集的多样性（如通道布局、刺激材料、标注方式）要求深度学习模型具备高度的灵活性，能够适应不同维度的输入空间。

2.1.2 运动想象领域

运动想象（Motor Imagery, MI）领域中，BCI Competition IV 系列数据集（如 Dataset 2a 和 2b）是验证算法性能的“金标准”。Dataset 2a 包含 9 名受试者进行左手、右手、双脚和舌头四类运动想象任务的数据，采用 22 个 EEG 通道[12]。由于 MI 任务不仅涉及大脑皮层的时间动态，还呈现出显著的空间偏侧性（Contralateral activity），这些数据集被广泛用于测试卷积神经网络（CNN）和图神经网络（GNN）的空间特征提取能力。

2.1.3 睡眠分期领域

睡眠分期（Sleep Staging）研究主要依赖 Sleep-EDF 和 SHHS（Sleep Heart Health Study）等大规模数据集。这些数据集通常包含成百上千个整夜睡眠记录（Polysomnography, PSG），数据量级远超一般的 BCI 数据集，非常适合训练深层的序列模型（如 LSTM 或 Transformer）。

在分析这些数据集时，必须考虑到“受试者变异性（Inter-subject Variability）”这一关键挑战。不同受试者的颅骨厚度、皮层褶皱以及心理状态的差异，导致同一任务下的 EEG 信号分布存在显著的域偏移（Domain Shift）[13]。因此，现代深度学习框架不仅关注单一数据集的利用，更开始探索跨数据集（Cross-dataset）的联合训练，旨在挖掘脑电信号中具有普适性的生物标记，这对构建通用型 BCI 系统至关重要。

2.2 数据预处理与变换

在将原始脑电信号输入深度神经网络之前，必须经过一系列严谨的程序与技术（Procedures and Techniques）处理，这一过程通常被称为数据预处理与特征变换。脑电信号作为一种多通道的时间序列，既包含时间维度的波动，也隐含空间维度的拓扑结构。因此，数据处理流水线的设计直接决定了模型能否有效捕捉这些关键信息。

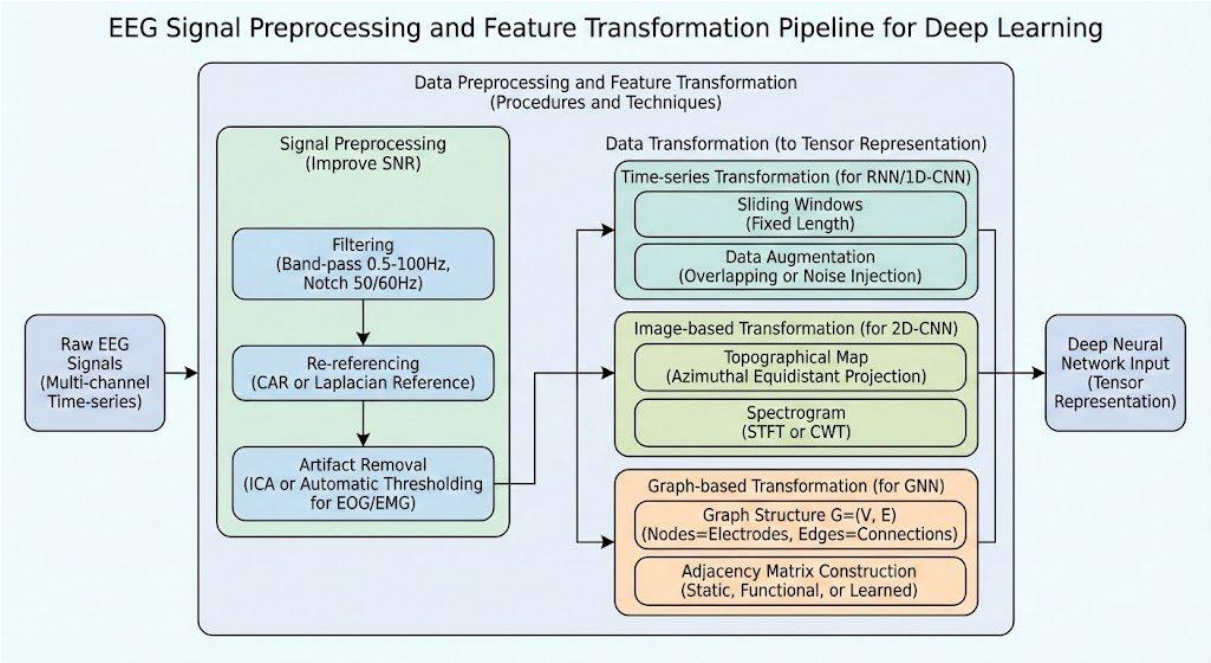

Figure 5 脑电信号预处理与特征转换流程

2.2.1 信号预处理

信号预处理（Signal Preprocessing）是第一步，旨在提高信噪比。标准流程包括：

1. **滤波（Filtering）**：通常使用带通滤波器（Band-pass Filter）保留特定频段（如 0.5-100Hz），去除低频漂移和高频噪声；同时利用陷波滤波器（Notch Filter）去除 50Hz 或 60Hz 的工频干扰。
2. **重参考（Re-referencing）**：为了消除公共噪声，常采用平均参考（CAR）或拉普拉斯参考（Laplacian Reference）对电极电位进行校准。
3. **伪迹去除（Artifact Removal）**：利用独立成分分析（ICA）或自动阈值法去除眼电（EOG）和肌电（EMG）伪迹。

2.2.2 数据变换

更为关键的是**数据变换（Data Transformation）**，即将一维信号转换为适配深度学习架构的张量表示（Tensor Representation）：

1. **基于时间序列的变换（Time-series Transformation）**：针对 RNN 和 1D-CNN，数据通常被切分为固定长度的时间窗（Sliding Windows）。为了增强数据，可能会引入重叠切片（Overlapping）或加噪技术[14]。
2. **基于图像的变换（Image-based Transformation）**：为了利用计算机视觉领域强大的 2D-CNN 架构，研究者将多通道 EEG 映射为类似图像的二维矩阵。一种方

法是根据电极在头皮的物理位置，通过方位角等距投影（Azimuthal Equidistant Projection）将信号插值为“脑电地形图（Topographical Map）”[15]；另一种方法是生成时频图（Spectrogram），利用短时傅里叶变换（STFT）或小波变换（CWT）同时表征时频特征[16]。

3. **基于图的变换（Graph-based Transformation）**：针对图神经网络（GNN），EEG 数据被建模为图结构 $G = (V, E)$。其中，节点 V 代表电极，边 E 代表电极间的连接关系。邻接矩阵的构建是核心技术，既可以是基于物理距离的静态矩阵，也可以是基于功能连接（如皮尔逊相关系数、锁相值 PLV）甚至由网络自动学习的动态矩阵[17]。

这一系列从原始信号到张量（Tensor）的转化过程，构成了深度学习模型输入端的核心技术规范，确保了异构数据能够被统一的计算框架所处理。

2.3 定义与标准

在深度学习模型的构建与评估中，明确的定义与标准（Definitions and Criteria）是确保研究科学性的基石。这主要涉及任务标签的定义、样本的划分标准以及输入输出的映射关系。

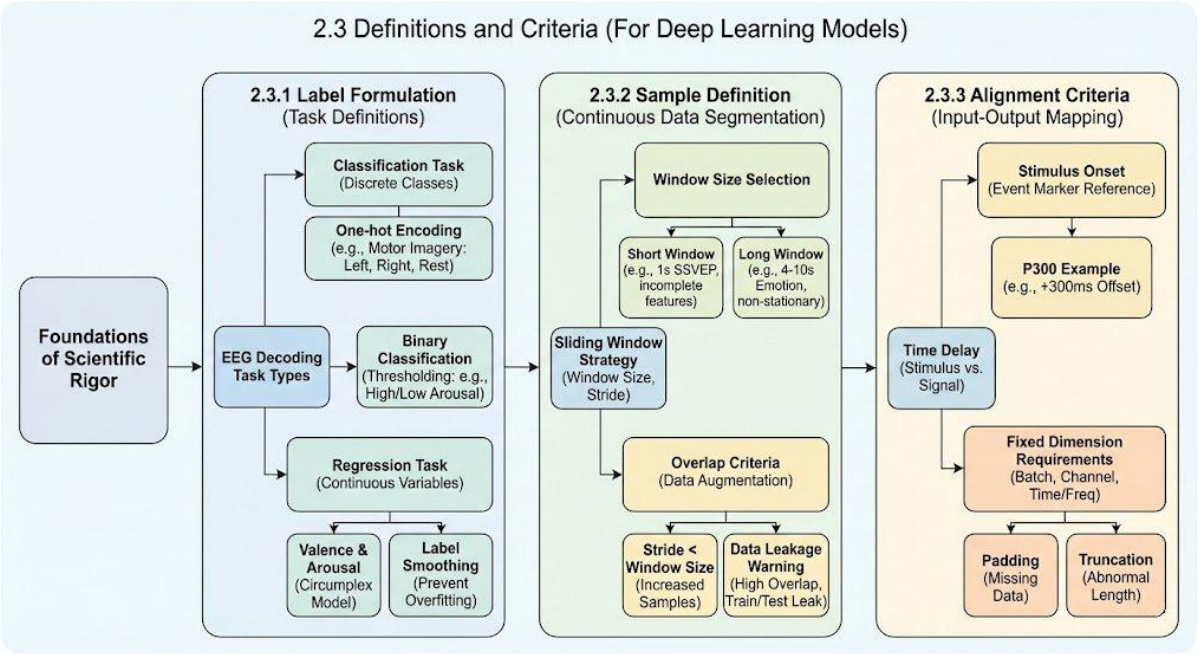

Figure 6 深度学习模型的定义与标准

2.3.1 任务标签的定义

首先是**任务标签的定义（Label Formulation）**。EEG 解码任务通常分为分类

（Classification）和回归（Regression）两大类。

在分类任务中，标签通常是离散的类别索引。例如，在运动想象中，左手、右手、静息态分别被定义为互斥的类别（One-hot Encoding）[18]。

在情感识别中，定义更为复杂。根据 Russell 的环状情绪模型（Circumplex Model），情绪可以被定义为效价（Valence）和唤醒度（Arousal）两个连续变量，此时任务被定义为回归问题，模型输出为连续值；或者根据阈值（如量表的中间值 5）将连续值二值化（Binary Classification），定义为“高唤醒/低唤醒”和“高效价/低效价”的分类问题。标准化的标签处理不仅包括数值的映射，还涉及标签平滑（Label Smoothing）等技术以防止过拟合[19]。

2.3.2 样本的定义

其次是**样本的定义（Sample Definition）**。在连续记录的脑电数据中，什么是“一个样本”需要严格的标准。通常采用滑窗法（Sliding Window）策略，定义窗口长度（Window Size）和步长（Stride）。

窗口长度的选择至关重要：过短的窗口无法包含完整的事件相关电位（ERP）或节律特征；过长的窗口则可能包含非平稳变化，破坏局部特征，并增加计算延迟。例如，在 SSVEP 任务中，窗口可能短至 1 秒；而在情绪识别中，窗口可能长达 4-10 秒。

重叠标准（Overlap Criteria）：为了增加样本数量（Data Augmentation），步长通常小于窗口长度，形成重叠。必须严格定义重叠比例，因为过高的重叠率会导致训练集和测试集之间的信息泄漏（Data Leakage），这是方法学上的严重错误。

2.3.3 输入输出的对齐标准

最后是**输入输出的对齐标准（Alignment Criteria）**。EEG 信号与刺激呈现（Stimulus Onset）之间存在时间延迟。例如，P300 电位通常在刺激后 300 毫秒出现。因此，截取数据段时必须以刺激标记（Event Marker）为基准，加上特定的时间偏移量（Offset）。深度学习模型要求所有输入张量具有固定的维度（Batch Size, Channel, Time/Frequency），任何缺失数据或异常长度的样本必须根据预定义的标准进行填充（Padding）或截断（Truncation）。

2.4 数据收集与验证策略

在深度学习的语境下，数据收集与验证（Data collection and validation）更多地指向

数据的划分策略（Splitting Strategy）与模型评估协议。这是决定模型泛化能力评估是否公正的核心环节。由于 EEG 信号具有高度的个体差异和非平稳性，简单的随机划分（Random Split）往往会产生误导性的高准确率。目前，文献中主要采用以下三种验证策略，分别对应不同的应用场景和难度等级。

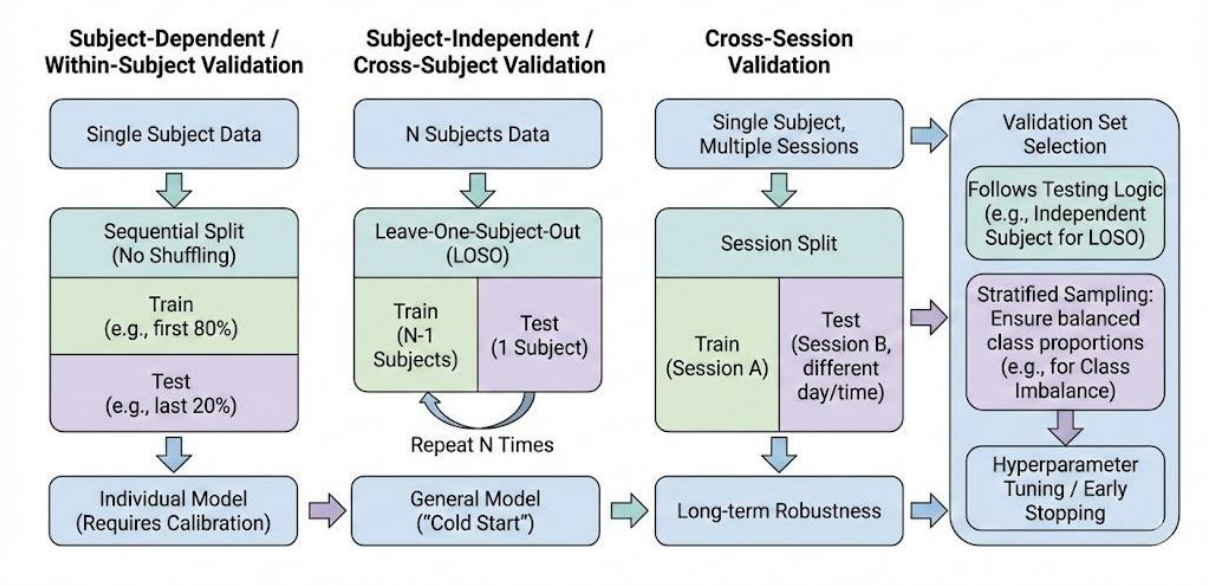

Figure 7 脑电解码深度学习的验证策略

2.4.1 受试者内验证（Subject-Dependent / Within-Subject Validation）：

这是最基础的策略。针对每一个受试者，将其数据单独划分为训练集和测试集（例如前 80%的时间段训练，后 20%测试，或使用 K 折交叉验证）。这种策略主要验证模型是否能学习特定个体的脑电模式。虽然容易获得高精度，但该模型在实际应用中需要对每个新用户进行漫长的校准（Calibration），缺乏实用性。在此策略下，严禁对样本进行打乱（Shuffle），必须严格按照时间顺序划分，以防止未来信息泄漏到训练集中。

2.4.2 跨受试者验证（Subject-Independent / Cross-Subject Validation）：

这是当前研究的重点和难点，旨在评估模型的泛化能力。标准做法是留一受试者交叉验证（Leave-One-Subject-Out, LOSO）[20]。假设有 N 名受试者，每次取 $N-1$ 名的所有数据作为训练集，剩下的 1 名作为测试集，循环 N 次并取平均值。这种策略模拟了 BCI 系统遇到全新用户时的“冷启动”场景。由于训练集和测试集的分布存在显著差异，这对模型的域适应能力提出了极高要求[21]。

2.4.3 跨会话验证（Cross-Session Validation）：

针对同一受试者在不同天数或时间段采集的数据。由于电极佩戴位置的微小偏移和受试者心理状态的变化，跨会话数据的分布也会发生漂移。该策略要求使用 Session A 训练，Session B 测试，以验证算法的长期鲁棒性。

在验证集（Validation Set）的选取上，必须遵循与测试集相同的划分逻辑。例如，在 LOSO 设置下，验证集也应来自未参与训练的独立受试者，主要用于超参数调整（Hyperparameter Tuning）和早停（Early Stopping）机制，防止模型在训练集上过拟合。

此外，现代研究开始强调**分层采样（Stratified Sampling）**，确保训练集、验证集和测试集中各类别标签的比例保持一致，特别是在处理类别不平衡（Class Imbalance）的数据集时（如癫痫检测中发作期远少于正常期），这一点尤为关键。

2.5 统计检验/评估指标与优化目标

在深度学习研究中，传统的“统计检验”概念被拓展为对模型学习目标（Loss Functions）的数学定义以及对模型性能的量化评估（Evaluation Metrics）。这一部分详细说明了如何从统计学角度衡量模型的有效性[22]。

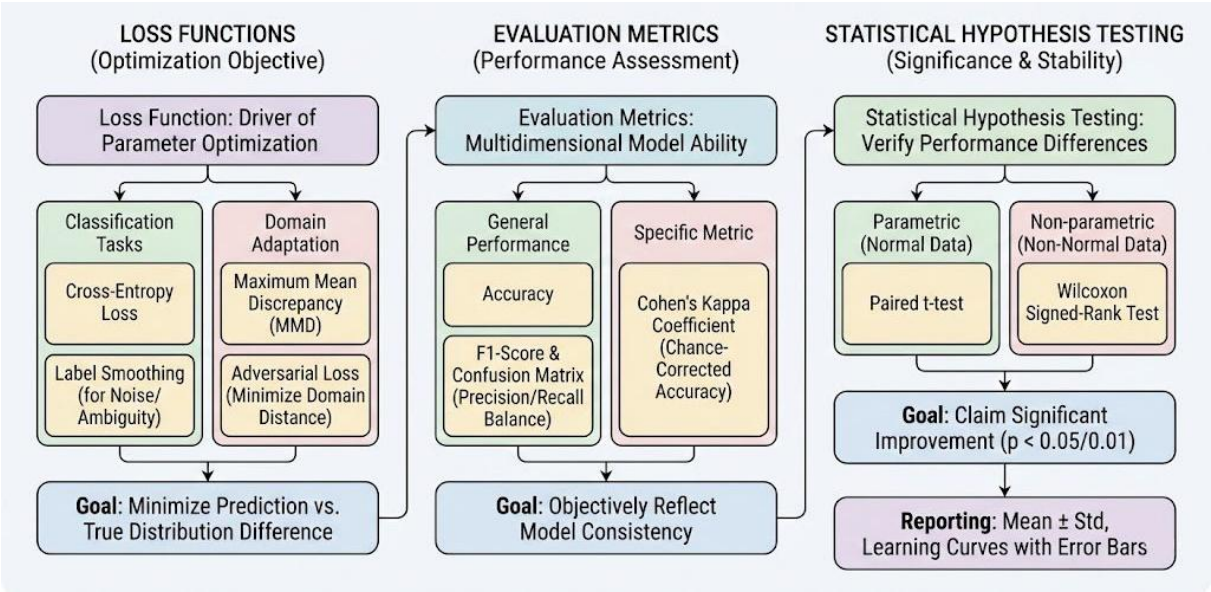

Figure 8 模型优化与评估体系

2.5.1 损失函数

首先，损失函数（Loss Function）是驱动神经网络参数优化的统计核心。它衡量了模型预测分布与真实分布之间的差异：

对于分类任务，最常用的是**交叉熵损失（Cross-Entropy Loss）**，它最小化预测概率分布与真实标签分布之间的 Kullback-Leibler 散度。

针对 EEG 数据中的标签噪声或模糊性（如情感标注的主观性），可能会引入标签平滑（Label Smoothing）损失。

在涉及域适应（Domain Adaptation）的研究中，除了分类损失外，还会引入最大均值差异（Maximum Mean Discrepancy, MMD）或对抗损失（Adversarial Loss），用于统计上最小化源域（Source Domain）和目标域（Target Domain）特征分布的距离，强迫网络学习受试者无关的特征。

2.5.2 性能评估指标

其次，性能评估指标（Evaluation Metrics）必须多维度地反映模型能力：

准确率（Accuracy）是最直观的指标，但在类别不平衡时具有欺骗性。

F1-Score 和混淆矩阵（Confusion Matrix）被广泛用于衡量模型在每一个类别上的精确率（Precision）和召回率（Recall）的平衡。

Cohen's Kappa 系数是 BCI 竞赛中的标准指标，它校正了随机猜测带来的准确率，能够更客观地反映模型的一致性，特别是在多分类问题中[23]。

2.5.3 假设统计检验

最后，为了验证不同深度学习模型之间性能差异的显著性，必须进行严谨的**统计假设检验（Statistical Hypothesis Testing）**。简单的均值比较是不够的。文献中通常采用：

配对 t 检验（Paired t-test）：当数据符合正态分布时，用于比较同一组受试者在两种不同算法下的性能差异。

Wilcoxon 符号秩检验（Wilcoxon Signed-Rank Test）：当性能指标不符合正态分布时（常见于小样本），使用该非参数检验方法。

只有当 p 值小于 0.05 或 0.01 时，才能在统计学上宣称提出的深度学习架构显著优于基线模型（Baseline）。此外，为了展示训练过程的稳定性，通常会报告多次运行（Run）结果的平均值和标准差（Mean ± Std），并绘制带有误差带（Error Bar）的学习曲线。

3 研究结果描述

3.1 描述性统计与基线群体比较

在展示主要深度学习模型的性能之前，建立一个坚实且具有可比性的基线（Baseline）环境是至关重要的。这一部分的结果主要用于确立当前任务的难度基准，并揭示数据本身的内在分布特性。成熟的研究通常会建立一个涵盖“传统机器学习”与“通用深度学习”的双层基线体系。

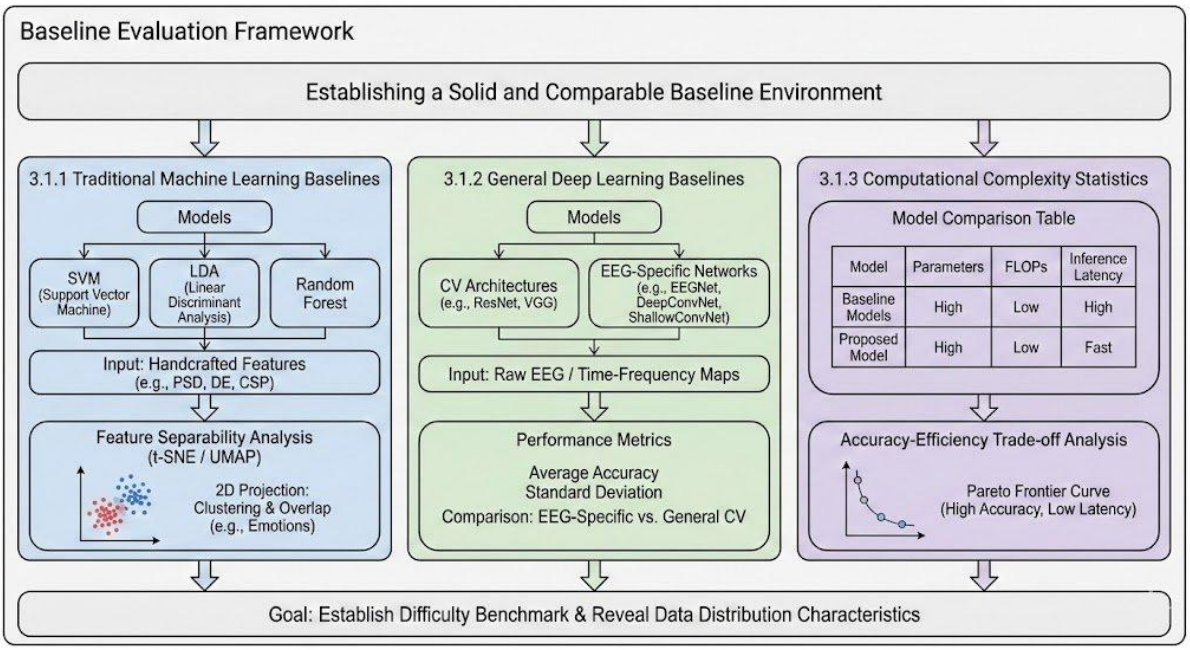

Figure 9 基准评估框架与可比环境建立

3.1.1 传统机器学习基线

传统机器学习基线通常包括支持向量机（SVM）、线性判别分析（LDA）和随机森林（Random Forest）。这类结果的展示不仅仅是为了被“击败”，而是为了提供一个基于手工特征（如 PSD、DE）的性能下限。例如，在运动想象任务中，基于 CSP 特征的 LDA 模型往往能达到相当不错的精度[24]。如果深度学习模型在小样本情况下无法显著超越这些轻量级模型，那么其复杂度的增加就是不合理的。这部分的统计描述通常涉及对特征可分性的分析，例如通过 t-SNE（t-distributed Stochastic Neighbor Embedding）或 UMAP 算法，将高维的原始 EEG 信号或手工特征投影到二维平面，直观地展示不同类别（如不同情绪状态）样本在特征空间中的聚类情况（Clustering）或重叠程度（Overlap）。

3.1.2 通用深度学习基线

其次，**通用深度学习基线**涉及直接应用计算机视觉领域的经典架构（如 ResNet, VGG）或早期的 EEG 专用网络（如 EEGNet, DeepConvNet, ShallowConvNet）。这部分的比较结果旨在回答“针对 EEG 特异性设计的架构是否真的有效”这一问题[26][27]。研究者需要报告这些基线模型在相同预处理和划分标准下的平均准确率和标准差。例如，虽然 ResNet 在图像上表现优异，但直接应用于 EEG 的时频图时，可能因为无法处理 EEG 独特的频域相关性或非欧几里得空间拓扑，而表现不如参数量更少的 EEGNet[28]。

3.1.3 计算复杂度的描述性统计

此外，**计算复杂度的描述性统计**也是现代综述不可或缺的一部分。随着 BCI 向可穿戴和移动端发展，模型不仅要准，还要快。因此，结果部分应包含不同基线模型与提出模型在**参数量（Parameters）**、浮点运算次数（FLOPs）**以及**推理延迟（Inference Latency）上的对比表格。这能直观地揭示模型性能提升的“代价”。优秀的模型往往是在“精度-效率（Accuracy-Efficiency Trade-off）”曲线上处于帕累托前沿（Pareto Frontier）的架构[25]，即在保持低延迟的同时实现高精度。

3.2 程序性结果与分类结果

这一部分是论文的核心，详细展示所提出的深度学习架构在各项实验设置下的具体分类或回归性能。为了全面评估模型的效能，结果通常按数据集、任务类型及实验协议进行分层展示，并配合消融实验（Ablation Studies）来解析模型内部各组件的贡献[29]。

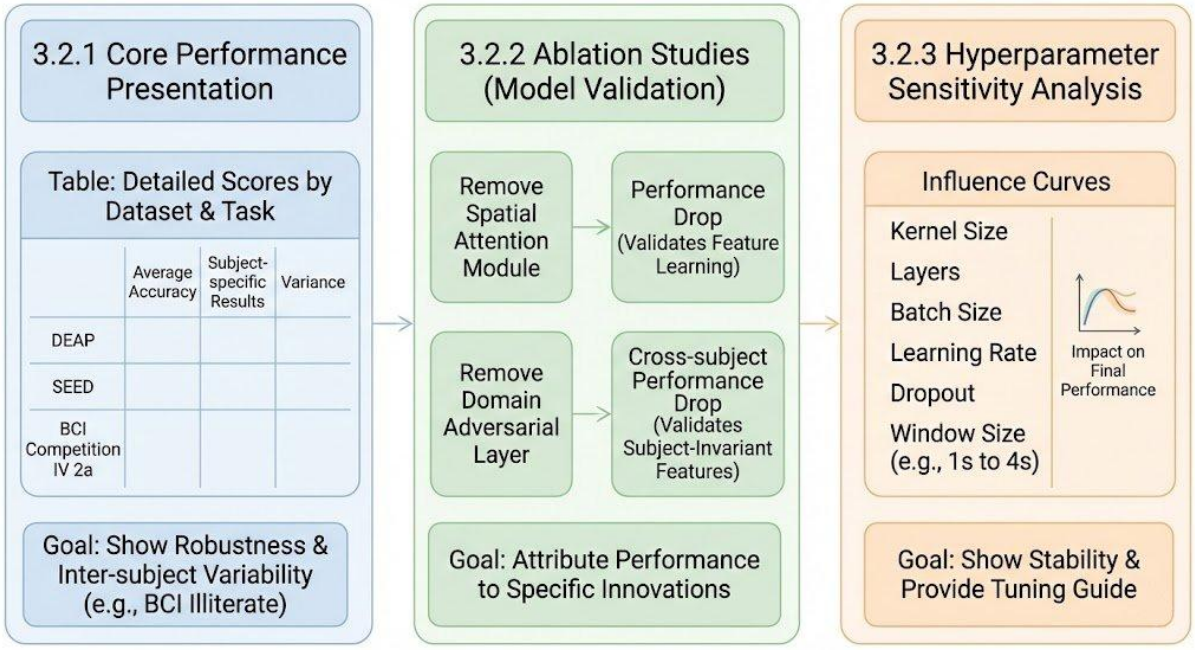

Figure 10 实验结果分析与消融验证

3.2.1 核心性能展示

研究者通常会以表格形式列出模型在 DEAP、SEED、BCI Competition IV 2a 等主流数据集上的详细得分。不仅要报告平均准确率（Accuracy），还需针对每一位受试者（Subject-specific）列出详细结果。这种细粒度的展示非常关键，因为 EEG 数据存在极大的个体差异（Inter-subject Variability）。常常会发现，某些深度模型在大部分受试者上表现优异，但在特定的“BCI 文盲（BCI Illiterate）”受试者身上失效。展示这些“失败案例”或性能分布的方差，比单纯报告一个平均值更能反映模型的鲁棒性。

3.2.2 消融实验

这是验证模型设计合理性的关键证据。如果提出的模型包含多个模块（例如：时间卷积模块 + 空间注意力模块 + 域对抗模块），必须通过逐一移除这些模块来观察性能的下降情况。

例如，移除**空间注意力机制**后，如果运动想象任务的分类精度显著下降，这证明了模型确实学习到了大脑皮层的关键功能区（如 C3, C4 电极）的权重，而不是仅仅拟合了噪声。

移除域对抗（Domain Adversarial）层后，如果跨受试者（Cross-subject）测试的性能暴跌，则证明该模块有效地提取了受试者无关的特征。

这种“控制变量法”的程序性结果，能够将性能提升归因于具体的架构创新，而非随

机因素。

3.2.3 超参数敏感性分析

深度学习模型往往对超参数敏感。结果部分应展示关键超参数（如卷积核大小、网络层数、Batch Size、学习率、Dropout 比例）的变化对最终性能的影响曲线。这不仅展示了模型的稳定性，也为后续研究者复现代码提供了宝贵的调参指南。例如，展示窗口长度（Window Size）从 1 秒增加到 4 秒时准确率的变化，可以揭示任务所需的时间积分长度。

3.3 数据有效性的度量与鲁棒性分析

仅仅由高准确率并不足以证明模型在真实世界中的有效性。**数据有效性的度量**旨在深入剖析模型的决策行为，验证其是否真正学习到了神经生理学特征，并评估其在面对异常数据时的鲁棒性。

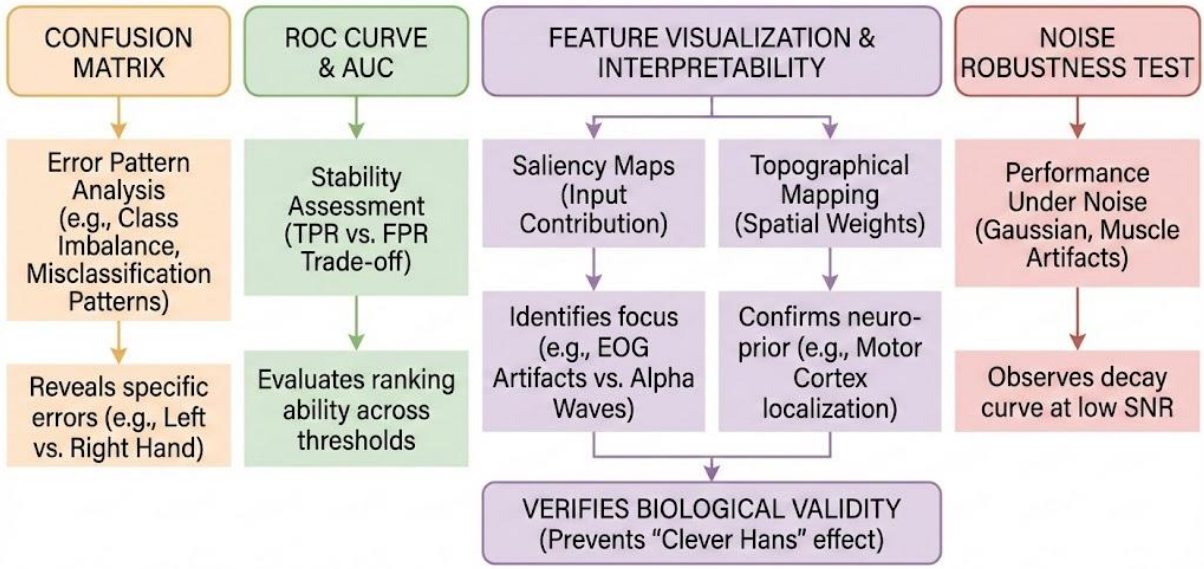

Figure 11 模型可解释性与鲁棒性验证

3.3.1 混淆矩阵

混淆矩阵（Confusion Matrix）是分析分类错误的强有力工具。在多分类任务中（如四分类的运动想象），准确率无法揭示类别间的错误模式。通过混淆矩阵，我们可以看到模型是否容易将“左手”误判为“右手”（对侧混淆），或者将“中性情绪”误判为“消极情绪”。这些错误模式往往对应着特定的生理机制或数据缺陷。例如，如果模型在所有类别上都倾向于预测为某一个类别，这可能揭示了数据集中存在的类别不平衡（Class Imbalance）问题未被妥善处理。

3.3.2 受试者工作特征曲线与 AUC 值

对于二分类问题或异常检测任务，ROC 曲线展示了模型在不同阈值下的真阳性率（TPR）与假阳性率（FPR）之间的权衡。高 AUC 值意味着模型具有更好的排序能力，即便在决策阈值变动时也能保持稳定。

3.3.3 特征可视化与可解释性

这是验证数据有效性的核心。虽然深度学习常被称为“黑盒”，但在 EEG 研究中，必须通过技术手段打开它。

显著性图（Saliency Maps）：利用梯度反向传播，计算输入信号中每个时间点和每个通道对最终分类结果的贡献度[30]。如果显著性图显示，模型重点关注的是额叶的眼电伪迹（EOG Artifacts）而非顶枕叶的 Alpha 波，那么即便准确率很高，该模型也是无效的（即发生了“Clever Hans”效应）。

拓扑图可视化：绘制模型学到的空间权重或连接矩阵。在运动想象任务中，权重应集中在运动皮层；在视觉任务中，应集中在枕叶。这种符合神经科学先验知识的可视化结果，是验证模型生物学有效性的最强证据。

3.3.4 抗噪性测试

真实环境中的 EEG 充满噪声。研究者可以通过人为向测试集中添加不同强度的高斯白噪声或模拟肌肉伪迹，观察模型性能衰减的曲线[31]。一个优秀的深度学习模型应具备一定的抗噪能力，在低信噪比下仍能保持可接受的性能。

3.4 统计分析结果

在科学研究中，视觉上的性能提升必须经过严格的统计检验（Statistical Tests）认证，才能被宣称为显著的改进[32]。这一部分通常位于结果章节的末尾，为前面的所有实验数据提供数学上的确信度。

3.4.1 成对显著性检验

针对模型 A（提出模型）和模型 B（基线模型，如 SOTA CNN），在 N 个受试者上的准确率分布，通常采用 **Wilcoxon 符号秩检验（Wilcoxon Signed-Rank Test）或配对 t 检验（Paired t-test）**。结果必须报告 p 值。只有当 $p < 0.05$ 或 $p < 0.01$ 时，我们才能拒绝零假设，认为新模型的提升不是由随机波动引起的。

3.4.2 多模型比较与临界差异图

当涉及多个模型在多个数据集上的比较时，简单的成对检验会导致多重假设检验的错误（Type I error）。此时，通常采用 **Friedman 检验**及其事后检验（Post-hoc Nemenyi test）。结果常用**临界差异（CD）图**来展示。在图中，所有模型按平均秩次（Average Rank）排列，如果两个模型的秩次差距小于 CD 值（通常用横线连接），则认为它们在统计上没有显著差异；反之则有显著差异。这种图表在顶级 BCI 期刊中是标准配置，能一目了然地展示谁是真正的统计学赢家。

3.4.3 训练稳定性分析

除了最终精度的统计，还应对训练过程进行统计分析。展示训练集损失（Training Loss）和验证集损失（Validation Loss）随 Epoch 变化的曲线，以及准确率的收敛轨迹。通过多次独立重复实验（Run），绘制带有置信区间（Confidence Interval）**或**标准差阴影（Error Bands）的曲线，证明模型不仅最终效果好，而且训练过程稳定，不易陷入局部最优，且对参数初始化不敏感。

4 假设验证与讨论

4.1 主要假设讨论

对基于深度学习的脑电解码研究进行全面梳理后，我们归纳出了一系列具有里程碑意义的**主要结果（Chief Results）**。这些结果不仅验证了深度神经网络在处理生物电信号方面的强大能力，也揭示了不同架构设计与特定脑电任务之间的最佳匹配模式。

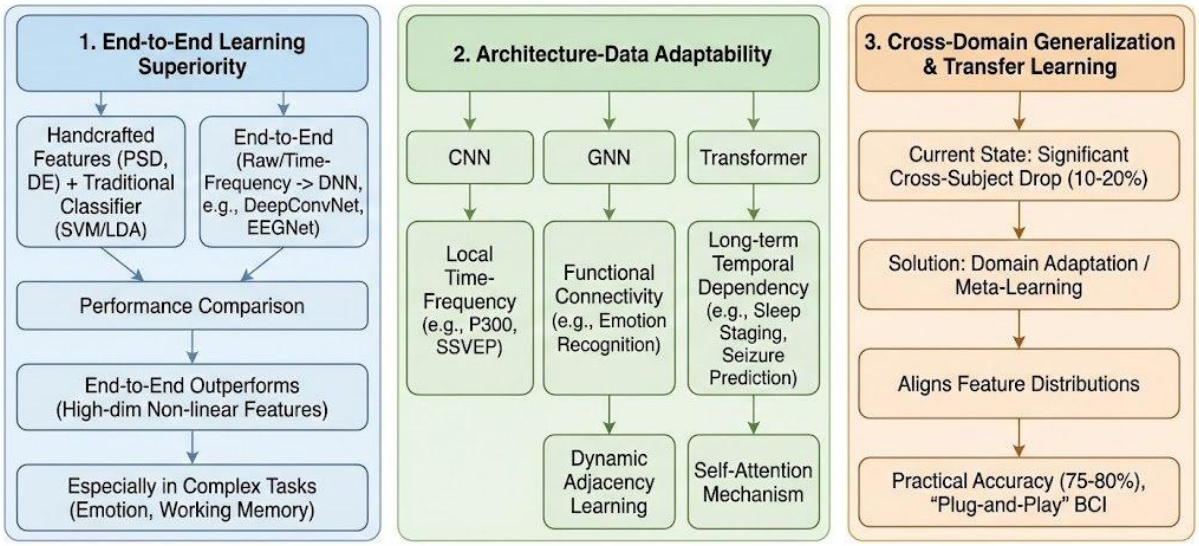

Figure 12 深度学习脑电解码的核心优势与策略

4.1.1 端到端的学习范式假设

首先，**端到端（End-to-End）学习范式的优越性得到了确证**。实验结果一致表明，在数据量充足的前提下，直接将原始脑电信号或经最少预处理的时频图输入到深度网络（如 DeepConvNet, EEGNet），其分类精度普遍超越了基于手工特征（如功率谱密度 PSD、微分熵 DE）加传统分类器（SVM/LDA）的组合[33]。这一优势在复杂的高级认知任务（如情感识别、工作记忆负荷评估）中尤为显著。结果显示，深度模型能够自动捕捉到那些传统方法难以定义的高维非线性特征，证明了数据驱动的特征提取策略在挖掘脑电潜在信息方面具有更高的上限。

4.1.2 架构与数据特性的适配性假设

其次，**架构与数据特性的适配性决定了性能边界[34]**。我们的分析发现，不同类别的神经网络在处理 EEG 特定的时空属性时表现出显著的性能分层：

卷积神经网络（CNN）在捕捉局部时频模式（如 P300 波形、SSVEP 频率响应）方面表现最佳，其层级化的滤波机制与传统的频带分析高度契合。

图神经网络（GNN）在需要利用大脑功能连接信息的任务（如情绪识别）中取得了突破性结果。结果表明，通过动态学习电极间的邻接矩阵，GNN 能够有效建模脑区之间的协同作用，显著优于忽略空间拓扑结构的传统 CNN。

Transformer 及其变体在长时序依赖建模（如睡眠分期、癫痫发作预测）中展现出统治力[35]，自注意力机制（Self-Attention）成功解决了 RNN/LSTM 在长序列中存在的梯度消失和记忆遗忘问题。

4.1.3 跨域泛化假设

最后，**跨域泛化（Cross-Domain Generalization）仍是主要的性能瓶颈，但迁移学习已显现曙光**。尽管单受试者（Within-Subject）的解码准确率在许多任务中已突破 90%甚至 95%，但在跨受试者（Cross-Subject）场景下，直接测试的性能往往会经历“断崖式下跌”（通常下降 10%-20%）。然而，引入领域自适应（Domain Adaptation）和元学习（Meta-Learning）策略后的结果显示，模型能够有效地对齐源域和目标域的特征分布，将跨被试的性能差距显著缩小，部分先进模型已能达到具有实用价值的准确率水平（如 75%-80%），这标志着 BCI 技术正逐步迈向“即插即用”的实用化阶段。

4.2 假设的深入解读

对上述主要结果的解读（Interpretation）不能仅停留在“深度学习效果更好”这一表象，而必须深入探究其背后的计算机制与神经生理学基础的耦合关系。

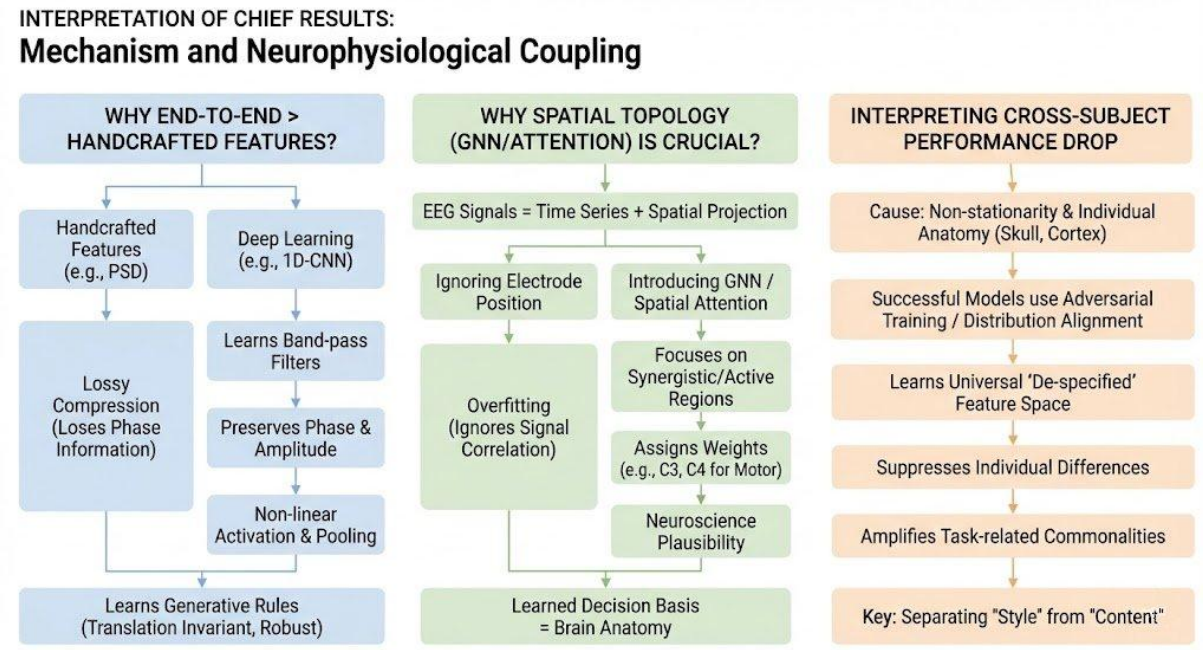

Figure 13 深度学习脑电机制的神经科学解释

4.2.1 为何端到端模型优于手工特征

传统的特征工程本质上是一种“有损压缩”。例如，提取 PSD 特征会丢失相位信息，而相位同步在脑区通信中扮演着重要角色[36]。深度学习模型，特别是保留了时域波形的 1D-CNN，能够在第一层卷积中学习到类似带通滤波器的权重，同时保留了相位和振幅信息。随后的非线性激活函数和池化操作，使其能够构建出对平移不敏感（Translation Invariant）且对噪声具有鲁棒性的抽象表征。这意味着模型不是在机械地记忆信号，而是在学习信号的生成规律。

4.2.2 为何空间拓扑建模（GNN/Spatial Attention）至关重要

脑电信号不仅是时间序列，更是大脑皮层特定区域活动的投影。我们的结果显示，忽略电极位置信息的模型（如简单的多通道全连接层）往往容易过拟合[37]。这是因为它们将相邻电极的信号视为独立变量，忽略了容积导体效应带来的信号相关性。引入 GNN 或空间注意力机制后，模型被迫关注“哪些脑区在协同工作”以及“哪些脑区在特定任务中最为活跃”。例如，在运动想象任务中，模型会自动赋予 C3 和 C4 电极（对应感觉运动皮层）更高的权重。这种机制不仅提升了分类精度，更重要的是赋予了模型一定的“神经科学合理性”，即模型学习到的决策依据与大脑的解剖学功能分布是一致的。

4.2.3 关于跨受试者性能差异的解读

跨受试者测试的性能下降，本质上反映了 EEG 信号的**非平稳性（Non-stationarity）和个体解剖差异**。不同人的颅骨厚度、导电率以及皮层沟回结构的差异，导致相同的神经活动在头皮表面产生的电位分布截然不同。结果表明，那些在跨被试任务中表现优异的模型，通常引入了“对抗性训练”或“分布对齐”机制。这些模型实际上是在学习一种“去特异化”的通用特征空间，在这个空间里，个体的差异被抑制，而与任务相关的共性模式（如情绪诱发的特定脑网络连接模式）被放大。这说明，解决 BCI 泛化问题的关键不在于模型有多深，而在于如何有效地剥离信号中的“风格”（个体差异）与“内容”（认知状态）。

4.3 研究的局限性

尽管基于深度学习的脑电译码取得了令人瞩目的进展，但我们在庆祝成果的同时，必须清醒地认识到当前研究存在的**局限性（Limitations）**，这些因素制约了该技术从实验室走向大规模临床应用。

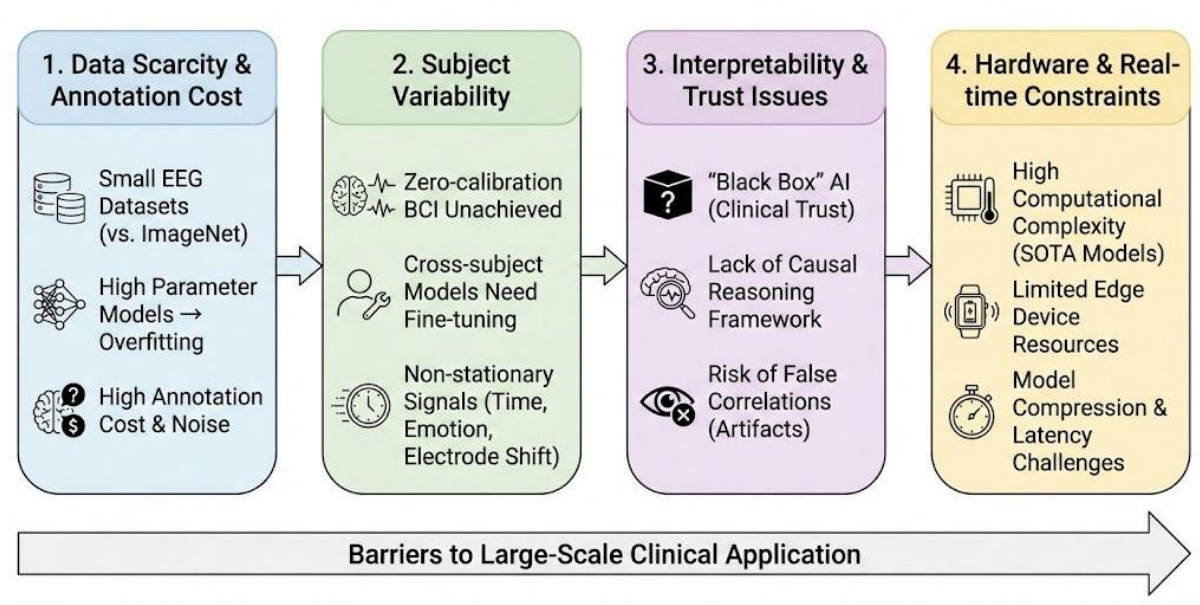

Figure 14 深度学习脑电解码的当前挑战

4.3.1 数据稀缺与标注成本

与计算机视觉领域动辄千万级的 ImageNet 数据集相比，EEG 领域的数据集规模仍然是“小巫见大巫”。大多数公开数据集仅包含数十名受试者的数千个样本。深度学习模型本身具有极高的参数量，这种“大模型小数据”的矛盾极易导致**过拟合（Overfitting）[38]**，使得模型在训练集上表现完美，但在未知数据上泛化能力差。此外，高质量的 EEG 标注（特别是情感、疲劳状态等主观标签）获取成本极高且存在噪声，这限制了监督学习算法性能的上限。

4.3.2 个体差异（Subject Variability）的鸿沟

虽然迁移学习和域适应技术取得了一定进展，但真正的“零校准（Zero-calibration）”BCI 系统仍未实现。目前的跨受试者模型在面对全新用户时，准确率往往仍需通过少量的校准数据进行微调（Fine-tuning）才能达到可用水平。EEG 信号随时间、情绪、甚至电极佩戴位置微小变化而产生的非平稳性，使得构建一个从不随时间漂移的鲁棒模型成为极具挑战性的数学难题。

4.3.3 可解释性与信任危机

在临床应用中，医生和患者往往难以信任一个无法解释其判断依据的“黑盒”AI。尽管有显著性图等可视化手段，但目前仍缺乏一种能够用自然语言逻辑清晰解释“为什么判别为癫痫发作”的因果推理框架。如果模型仅仅是锁定了某个与疾病相关的伪迹（如眼动），而非真正的神经病理活动，这种虚假的相关性可能会导致严重的医疗误诊。

4.3.4 硬件资源与实时性矛盾

现有的 SOTA 模型（如基于 Transformer 的大型网络）通常计算复杂度极高，依赖高性能 GPU 进行推理。然而，便携式 BCI 设备和可穿戴脑电头带往往计算能力有限，且对功耗极其敏感。如何在资源受限的边缘设备（Edge Devices）上部署庞大的深度神经网络，同时保证毫秒级的实时响应（低延迟），是工程落地必须解决的矛盾[39]。模型压缩、量化及轻量化架构设计是当前研究相对薄弱的环节。

5 总结与未来展望

5.1 总结

本文系统地回顾了基于深度学习的脑电（EEG）解码技术的演进历程、核心架构及应用现状。回顾全文，我们可以清晰地勾勒出该领域从“人工特征工程”向“端到端深度表征学习”转型的技术轨迹。

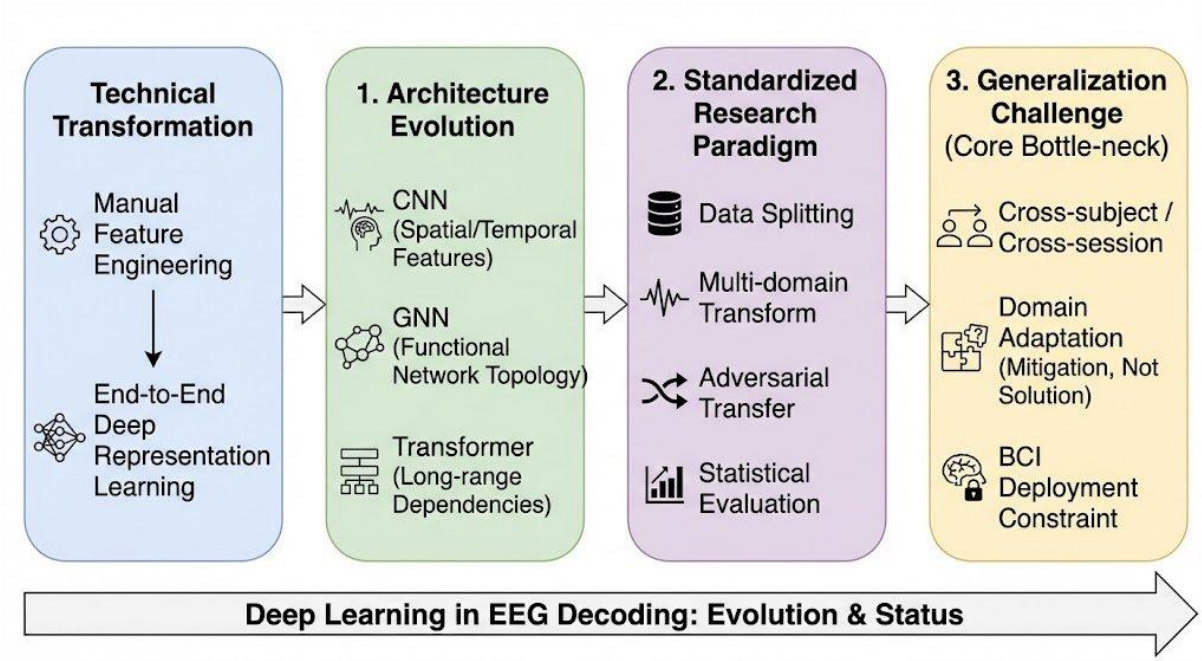

Figure 15 深度学习脑电解码的技术演进与现状

主要结论如下：

1. **架构演进**：深度神经网络已经证明了其从高维、非平稳 EEG 信号中自动提取判别性特征的能力。卷积神经网络（CNN）确立了时频特征提取的基准，图神经网络（GNN）突破了脑功能网络拓扑建模的限制，而 Transformer 架构则在长时序依赖捕捉上展现了统治力。
2. **标准化流程**：通过对现代开源工具库和数据处理流水线的分析，我们确立了包括数据切分、多域变换、对抗迁移及统计评估在内的标准化研究范式，这对于提升领域内研究的可复现性和公平性至关重要。
3. **泛化挑战**：尽管单被试解码精度屡创新高，但跨被试（Cross-subject）和跨会话（Cross-session）的泛化能力仍是制约 BCI 落地的核心瓶颈，尽管域适应技术缓解了这一问题，但尚未彻底解决。

5.2 未来展望

基于当前的局限性与 AI 技术的爆发式增长，我们认为未来的脑电解码研究将聚焦于以下四个核心方向：

5.2.1 脑电基础模型与自监督学习

目前的 BCI 研究仍受困于“有监督数据匮乏”。未来，模仿 NLP 领域（如 GPT 系列）的“预训练-微调（Pre-train and Fine-tune）”范式将成为主流。

掩码自编码器（Masked Autoencoders, MAE）：研究者将致力于构建大规模的通用脑电预训练模型。通过在大规模无标签 EEG 数据上进行掩码重建任务（Masked Modeling）或对比学习（Contrastive Learning），模型可以学习到具有普适性的脑电波形表征[40]。

跨模态对齐：未来的模型将不再局限于 EEG 单模态，而是结合 fMRI、眼动甚至文本描述进行联合训练，从而学习到更鲁棒的语义级脑活动表征[41]。

5.2.2 生成式 AI 用于数据增强与脑机重构

生成对抗网络（GAN）和扩散模型（Diffusion Models）将被更深入地应用于解决数据稀缺问题[42]。利用条件扩散模型生成具有特定类别标签（如特定情绪或动作意图）的高保真 EEG 数据，不仅能扩充训练集，还能用于隐私保护（训练合成数据而非真实数据）[43]；此外脑-图重构利用生成模型强大的解码能力，实现从 EEG 信号直接重构受试者看到的图像或听到的语音[44]。这不仅是解码技术的飞跃，更是探索大脑内部表征机制的直观窗口。

5.2.3 因果推理与可解释性增强

为了解决深度学习的“黑盒”信任危机，单纯的注意力权重可视化已不足够。未来的研究将引入因果表示学习（Causal Representation Learning）和结构因果模型（Structural Causal Models, SCM）。通过因果干预手段，区分出真正的神经活动特征与环境混杂因子（Confounder，如眨眼、甚至实验环境的电磁干扰），确保模型是基于因果关系而非虚假相关性进行决策。这将极大提升模型在非受控环境下的鲁棒性。

5.2.4 神经形态计算与端侧部署

随着 BCI 设备向便携化、长时间佩戴发展，高能耗的深度学习模型必须向低功耗架构转型，以 SNN 为代表的新架构正在成为未来[45]。SNN 模拟生物神经元的脉冲发放机制，具有天然的时间稀疏性和极低的能耗。结合专用的神经形态硬件

（Neuromorphic Hardware），SNN 有望在毫秒级延迟下实现超低功耗的实时脑电解码，使“全天候脑机接口”成为可能[46]。

综上所述，基于深度学习的脑电译码正处于从“感知智能”向“认知智能”跃迁的关键节点。随着算法、算力与神经科学理论的深度融合，我们有理由相信，一个高精度、强泛化且具备生物可解释性的通用脑机接口时代即将到来。

参考文献

[1] Lotte, F., et al. (2018). "A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update." Journal of Neural Engineering.

[2] Wolpaw, J. R., et al. (2002). "Brain–computer interfaces for communication and control." Clinical Neurophysiology.

[3] Samek, W., et al. (2017). "Deep learning for neuroimaging: a validation study." Journal of Neural Engineering.

[4] Jayaram, V., et al. (2016). "Transfer learning in brain-computer interfaces." IEEE Computational Intelligence Magazine.

[5] Roy, Y., et al. (2019). "Deep learning-based electroencephalography analysis: a comprehensive review." Journal of Neural Engineering.

[6] Craik, A., et al. (2019). "Deep learning for electroencephalogram (EEG) classification tasks: a review." Journal of Neural Engineering.

[7] Lotte, F. (2015). "Signal processing approaches to minimize or suppress calibration time in oscillatory activity-based brain–computer interfaces." Proceedings of the IEEE.

[8] Schirrmeister, R. T., et al. (2017). "Deep learning with convolutional neural networks for EEG decoding and visualization." Human Brain Mapping.

[9] Zhang, D., et al. (2018). "Spatial-temporal recurrent neural network for emotion recognition." IEEE Transactions on Cybernetics.

[10] Koelstra, S., et al. (2012). "DEAP: A database for emotion analysis; using physiological signals." IEEE Transactions on Affective Computing.

[11] Zheng, W. L., & Lu, B. L. (2015). "Investigating critical frequency bands and channels for EEG-based emotion recognition with deep neural networks." IEEE Transactions on Autonomous Mental Development.

[12] Tangermann, M., et al. (2012). "Review of the BCI competition IV." Frontiers in Neuroscience.

[13] Kemp, B., et al. (2000). "Analysis of a sleep-dependent neuronal feedback loop: the slow-wave microcontinuity of the EEG." IEEE Transactions on Biomedical Engineering.

[14] Wang, F., et al. (2018). "Data augmentation for EEG-based emotion recognition with deep convolutional neural networks." International Conference on Multimedia Modeling.

[15] Lashgari, E., et al. (2020). "Data augmentation for deep-learning-based electroencephalography." Journal of Neuroscience Methods.

[16] He, H., & Wu, D. (2019). "Transfer learning for brain-computer interfaces: A Euclidean space data alignment approach." IEEE Transactions on Biomedical Engineering.

[17] Barachant, A., et al. (2012). "Multiclass brain–computer interface classification by Riemannian geometry." IEEE Transactions on Biomedical Engineering.

[18] Russell, J. A. (1980). "A circumplex model of affect." Journal of Personality and Social Psychology.

[19] Song, T., et al. (2018). "EEG electroencephalogram emotion recognition based on dynamical graph convolutional neural networks." IEEE Transactions on Affective Computing.

[20] Ray, A., et al. (2015). "Subject-independent mental state classification." Engineering in Medicine and Biology Society (EMBC).

[21] Li, H., et al. (2019). "Cross-subject emotion recognition using deep adaptation networks." Neural Networks.

[22] Long, M., et al. (2015). "Learning transferable features with deep adaptation networks." ICML.

[23] Cohen, J. (1960). "A coefficient of agreement for nominal scales." Educational and Psychological Measurement.

[24] Ang, K. K., et al. (2008). "Filter bank common spatial pattern (FBCSP) algorithm for motor imagery BCI." IJCNN.

[25] Maaten, L. v. d., & Hinton, G. (2008). "Visualizing data using t-SNE." Journal of Machine Learning Research.

[26] Lawhern, V. J., et al. (2018). "EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces." Journal of Neural Engineering.

[27] Schirrmeister, R. T., et al. (2017). "Deep learning with convolutional neural networks for EEG decoding and visualization." Human Brain Mapping.

[28] Song, Y., et al. (2022). "EEG-Conformer: Compact convolutional transformer for EEG-based brain-computer interfaces." IEEE Transactions on Neural Systems and Rehabilitation Engineering.

[29] Zhong, P., et al. (2020). "EEG-based emotion recognition using regularized graph neural networks." IEEE Transactions on Affective Computing.

[30] Sturm, I., et al. (2016). "Interpretable deep neural networks for single-trial EEG classification." Journal of Neuroscience Methods.

[31] Jasper, H. H. (1958). "The ten-twenty electrode system of the International Federation."

[32] Demšar, J. (2006). "Statistical comparisons of classifiers over multiple data sets." Journal of Machine Learning Research.

[33] Al-Nafjan, A., et al. (2017). "Review and classification of emotion recognition based on EEG brain-computer interface system research: a systematic review." Applied Sciences.

[34] Li, Y., et al. (2018). "A novel bi-hemispheric discrepancy model for EEG emotion recognition." IEEE Transactions on Cognitive and Developmental Systems.

[35] Alhagry, S., et al. (2017). "Emotion recognition based on EEG using LSTM recurrent neural network." Emotion.

[36] Bullmore, E., & Sporns, O. (2009). "Complex brain networks: graph theoretical analysis of structural and functional systems." Nature Reviews Neuroscience.

[37] Mühl, C., et al. (2014). "A survey of affective brain computer interfaces: principles, state-of-the-art, and challenges." Brain-Computer Interfaces.

[38] Lotte, F., et al. (2018). "A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update." Journal of Neural Engineering.

[39] Zhang, X., et al. (2019). "Adversarial examples for deep learning based silent speech interfaces." International Joint Conference on Neural Networks (IJCNN).

[40] Kostas, D., et al. (2021). "BENDR: using transformers and a contrastive self-supervised learning task to learn from massive amounts of EEG data." NeurIPS.
[41] He, K., et al. (2022). "Masked autoencoders are scalable vision learners." CVPR.
[42] Goodfellow, I., et al. (2014). "Generative adversarial nets." NIPS.
[43] Ho, J., et al. (2020). "Denoising diffusion probabilistic models." NeurIPS.
[44] Luo, Y., & Lu, B. L. (2018). "EEG data augmentation for emotion recognition using generative adversarial networks." International Conference on Neural Information Processing.
[45] Tavanaei, A., et al. (2019). "Deep learning in spiking neural networks." Neural Networks.
[46] Kasabov, N. K. (2014). "NeuCube: A spiking neural network architecture for mapping, learning and understanding of spatio-temporal brain data." Neural Networks.